ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO

THE EAR AS A BIOMETRICS

Môn học: Nhận dạng

Giảng viên hướng dẫn: Thầy Lê Hoàng Thái

Thầy Lê Thanh Phong

Nhóm 11:

1. Lê Duy Mẫn - 19120574
2. Phan Thanh Tuyển - 19120711
3. Nguyễn Thanh Tân - 20120369
4. Nguyễn Tấn Chữ - 20120443

Thành phố Hồ Chí Minh - 2023

MUC LUC

THÔNG TIN NHÓM

MSSV	Họ và tên	Công việc	Đánh giá
20120443	Nguyễn Tấn Chữ	Tìm hiểu chung về chủ đề, cấu trúc tai. Phát biểu bài toán, động lực nghiên cứu	Hoàn thành
19120574	Lê Duy Mẫn	Tìm tài liệu, tìm hiểu chung về chủ đề. Related works, phương pháp	Hoàn thành
20120369	Nguyễn Thanh Tân	Tìm tài liệu, làm slide, làm về phần related work và CNN	Hoàn thành
19120711	Phan Thanh Tuyển	Tìm tài liệu, dataset và làm phần demo	Hoàn thành

1. Giới thiệu đề tài

Trong các đặc điểm sinh lý học khác nhau, tai đã được nhiều người quan tâm trong những năm gần đây vì được cho là một đặc trưng nhận dạng con người đáng tin cậy.

Tiềm năng của nhận dạng bằng tai đã được công nhận và khuyến khích trong khoảng thời gian dài trước đó vào năm 1890 bởi nhà tội phạm học người Pháp Alphonse Bertillon. Ông đã viết trong 1 công trình về sinh trắc học rằng:

> "The ear, thanks to these multiple small valleys and hills which furrow across it, is the most significant factor from the point of view of identification. Immutable in its form since birth, resistant to the influences of environment and education, this organ remains, during the entire life, like the intangible legacy of heredity and of the intra-uterine life".

Nhận dạng tai không được chú ý nhiều như những phương pháp nhận dạng mặt, mống mắt, vân tay. Tuy nhiên, tai đã đóng vai trò quan trọng trong khoa học pháp y trong suốt nhiều năm, đặc biệt tại Hoa Kỳ có 1 hệ thống phân loại tai dựa trên cách đo thủ công được phát triển bởi Alfred Victor Iannarelli, hệ thống này đã được sử dụng trong hơn 40 năm. Sinh trắc học tai đã được sử dụng để nhận ra các cặp song sinh giống hệt nhau vì các đặc điểm phân biệt của nó.

2. Cấu trúc của tai

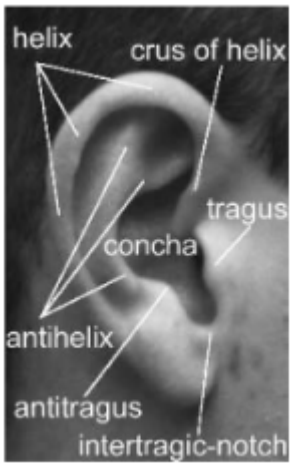

Các nghiên cứu chỉ ra rằng cấu trúc của tai không phải là ngẫu nhiên mà là có cấu trúc xác định như khuôn mặt. Hình dáng của tai thường bị chi phối bởi vành ngoài của tai (helix) và hình dạng của thùy tai (lobe).

- Có một vành trong của tai (inner helix hay antihelix) chạy song song với vành ngoài của tai (helix) nhưng chia thành 2 nhánh ở đầu trên. Vành trong (inner helix) và nhánh thấp hơn của hai nhánh này tạo thành phía trên và bên trái của ổ tai (concha). Phía dưới của concha hợp nhất vào rãnh giữa tai (intertragic-notch) và có độ cong rất sâu ở dưới cùng có thể tạo thành một điểm tham chiếu hữu ích cho mục đích sinh trắc học. Chú ý crus of helix là nơi helix giao với nhánh dưới của antihelix. Đây là một trong những điểm được Iannarelli sử dụng làm điểm tham chiếu cho hệ thống đo lường của ông, điểm tham chiếu khác là antitragus hoặc cái bướu nhỏ ở bên trái của rãnh giữa tai (intertragic-notch) .
- Phía trước của concha mở ra thành kênh tai ngoài hoặc vòm tai nghe, thường được gọi là lỗ tai, mặc dù điều này thường bị giấu kín bởi da xung quanh và phía trên cái bướu.

- Hình trên thể hiện một mẫu nhỏ của các tai người, cho thấy sự đa dạng phong phú của các hình dạng khác nhau. Lưu ý rằng một số tai có thùy tai rõ ràng, trong khi các tai khác lại gần như không có thùy. Những tai sau được gọi là "thùy gắn kết" và làm cho việc đo chiều dài tai trở nên khó khăn.
- Do xu hướng của vòng ngoài và trong helices chạy song song, nên có một mức độ tương quan khá cao giữa chúng, làm giảm giá trị sinh trắc học của tai; thực tế có thể còn có lý luận rằng khu vực concha chỉ là khoảng trống còn lại sau khi các phần khác đã được xác định, do đó nó cũng rất tương quan với các phần láng giềng của nó và do đó đóng góp ít thông tin độc lập hơn những gì có vẻ ban đầu.
- Vòng tai ngoài gọi là auricula hoặc pinna chỉ chiếm phần của tổ chức tai toàn bộ đã tiến hóa để xác định, thu thập và xử lý sóng âm. Nhiều loài động vật khác như ngựa, chó và mèo có thể di chuyển tai để tìm kiếm các nguồn âm thanh cụ thể tốt hơn. May mắn cho mục đích sinh trắc học, chúng ta, con người, gần như không thể di chuyển tai; tai của chúng ta được giữ nguyên vị trí cứng nhắc bởi các mô sụn được gắn chặt vào xương bên của đầu.
- Khuôn mặt có độ phức tạp hình ảnh tương tự như tai; những thay đổi đơn giản trong các thông số xác định kích thước và hình dạng của mắt, mũi, miệng và xương gò má có thể dẫn đến nhiều diện mạo khuôn mặt khác nhau. Trong đó, chúng ta coi sự đối xứng hoàn hảo là một dấu hiệu của vẻ đẹp, nhưng chúng ta cũng nên lưu ý rằng tai không có đối xứng. Điều đó cũng đáng lưu ý là vì khuôn mặt có tính đối xứng quanh trục tâm của nó, do đó cấu trúc thực sự chỉ đại diện

cho một nửa khuôn mặt từ quan điểm sinh trắc học vì thông tin phía bên trái phản ánh thông tin phía bên phải. Tai không có đối xứng và do đó không bị ảnh hưởng bởi hạn chế biến đổi liên quan đến ngoại cảnh, điều này đem lại lợi thế cho nó so với khuôn mặt. Và tất nhiên, khuôn mặt bị bóp méo trong khi nói và khi diễn tả cảm xúc, và diện mạo của nó thường bị thay đổi bởi trang điểm, kính, râu và ria mép, trong khi tai không di chuyển và chỉ cần hỗ trợ cho các khuyên tai, khung kính kính và đôi khi là các thiết bị trợ thính, mặc dù tất nhiên nó thường bị che khuất bởi tóc. Vì vậy, tai ít bị ảnh hưởng bởi sự can thiệp của các yếu tố liên quan hơn nhiều so với nhiều sinh trắc học khác, đặc biệt là không bị ảnh hưởng bởi tuổi tác.

3. Động lực nghiên cứu

3.1 Lợi ích của sinh trắc học tai

- Tai được cho là rất ổn định. Các nghiên cứu y học đã cho thấy thay đổi lớn về hình dạng của tai chỉ xảy ra trước độ tuổi 8 và sau độ tuổi 70. Hình dạng của tai được cho là ổn định trong phần còn lại của cuộc đời.
- Tai rất đồng nhất và không thay đổi hình dạng khi mặt thay đổi biểu cảm.
- Phân phối màu sắc của tai gần như đồng đều.
- Xử lý nền trong trường hợp của tai rất dễ dàng vì nó luôn nằm ở giữa khuôn mặt.
- Tai không bị ảnh hưởng bởi mỹ phẩm và kính áp tròng.
- Tai có thể được sử dụng như một dạng sinh trắc học thông qua việc quan sát và thu thập dữ liệu mà không cần sự hợp tác nhiều từ đối tượng. Dữ liệu về tai có thể được thu thập một cách dễ dàng mà không cần sự đồng ý của đối tượng từ khoảng cách xa.
- Tai có thể được sử dụng độc lập hoặc kết hợp với khuôn mặt để tăng cường độ chính xác trong nhận dạng.

3.2 Tính ứng dụng

- Có thể kết hợp với nhận diện khuôn mặt để tăng độ chính xác trong nhận diện người.
- Sử dụng trong các ứng dụng an ninh bảo mật, truy tìm tội phạm.
- Sử dụng trong ngành y tế để xác định danh tính bệnh nhân khi khuôn mặt bị biến dạng.
- Sinh trắc học tai đã được sử dụng để nhận ra các cặp song sinh giống hệt nhau vì các đặc điểm phân biệt của nó

4. Bài toán

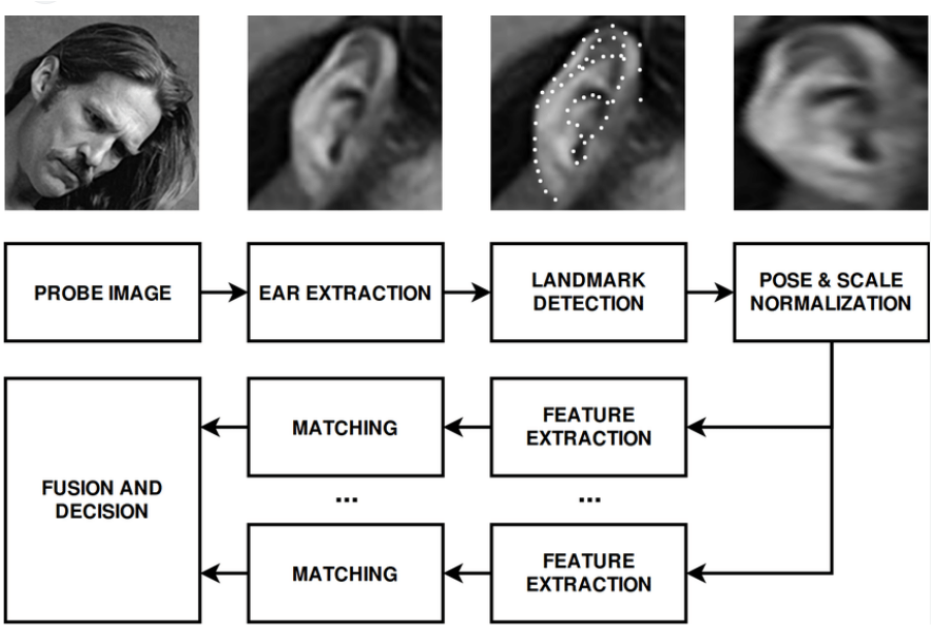

Nhận dạng danh tính của 1 người thông qua tai của người đó.

- Project statement: Phát hiện & Nhận diện
- Input: Ảnh 2D chứa 1 đối tượng tai người cần nhận diện.
- Output: Mask bao đối tượng và ID người phù hợp nhất với đối tượng trong database.

Một hình ảnh từ thư mục hoặc máy ảnh được cung cấp làm đầu vào cho hệ thống. Nó chỉnh sửa hình ảnh, thực hiện tiền xử lý, trích xuất tính năng, phân loại, đào tạo và sau đó nhận dạng người.

5. Related work

5.1 Ear Recognition Based on Deep Convolutional Network

- Tác giả: Liang Tian, Zhichun Mu
- Tạp chí/ hội nghị: 2016 9th International Congress on Image and Signal Processing, Bio-Medical Engineering and Informatics

Sử dụng mạng neural tích chập cho hệ thống nhận diện tai. Trong quá trình huấn luyện, ta tiếp nhận toàn bộ tham số của mạng qua quá trình lan truyền tiến và độ lỗi qua lan truyền ngược. Hệ thống này có thể trích xuất được đặc trưng mức thấp lẫn mức cao của tai. Những đặc trưng học này tốt hơn đặc trưng truyền thống được tạo bằng thủ công. Trong bài báo trên, điều chúng ta cần là thiết kế một mạng neural và sử dụng phương pháp thích hợp để huấn luyện cho mạng.

5.2 A Review on Biometrics and Ear Recognition Techniques

- Tác giả: Sukhdeep Singh, Dr. Sunil Kumar Singla
- Tạp chí/ hội nghị: IJARCSSE Volume 3, Issue 6, June 2013

Nền của một tấm ảnh tai người rất dễ đoán bởi vì nó luôn nằm một phía của đầu trong khi nhận diện mặt thường yêu cầu nền của tấm ảnh phải được kiểm soát để mang lại hiệu quả cao mà tình huống đó thì không phải lúc nào cũng đạt được. Không giống như mống mắt, võng mạc hay vân tay, tai không yêu cầu phải tiếp xúc gần để chụp lại. Tai cũng đóng vai trò quan trọng trong khoa học pháp y. Toàn bộ công nghệ nhận dạng và xác thực vận hành qua 4 pha:

- Pha chụp: Một mẫu sẽ được chụp lại bằng máy ảnh trong quá trình ghi danh và cả trong quá trình nhận dạng hoặc xác thực. Có thể sử dụng bất kỳ máy ảnh kỹ thuật số nào và dễ sử dụng
- Pha trích xuất: Một dữ liệu độc nhất được trích xuất từ mẫu bằng cách sử dụng nhiều kỹ thuật khác nhau. Một mẫu hình được tạo ra bằng Matlab và Lab VIEW
- Pha so sánh: Mẫu hình được so sánh với mẫu gốc.
- Khớp/Không khớp: Pha này trả về kết quả mẫu mới khớp hay không khớp.

5.3 A Review Paper on Ear Recognition Techniques: Models, Algorithms and Methods

- Những năm 1980 ở Hoa Kỳ, Iannarelli đã phát triển một hệ thống mô tả đặc trưng tai có ích, phục vụ cho việc nhận dạng cá nhân. Một hệ thống nhận dạng tai giống với hệ thống nhận dạng khuôn mặt và bao gồm 5 thành tố: Tạo cơ sở dữ liệu ảnh, tiền xử lý, trích xuất đặc trưng, huấn luyện mô hình và khớp mẫu hình.
- Alvarez et al. (2005) sử dụng thuật toán contour hiệu chỉnh và mô hình Ovoid để phân biệt tai. Saleh et al. (2006) thử nghiệm một tập dữ liệu về hình ảnh tai sử dụng một vài bộ phân lớp dựa trên hình ảnh và một vài phương pháp trích chọn đặc trưng. Kết quả cho thấy hiệu suất đạt từ 76.5% đến 94.1% dựa trên từng thực nghiệm của họ.
- Islam et al. (2008) đề xuất phương pháp nhận dạng tai dựa trên thuật toán AdaBoost, mô hình này nhạy cảm với nhiễu và ngoại lai trong dữ liệu.
- Hệ thống do Islam et al (2007) phát triển hệ thống dựa trên đặc trưng Haar-like và sử dụng tập dữ liệu bao gồm nhiều sắc tộc, giới tính, hình dạng, độ nghiêng và độ sáng khác nhau

5.4 Training CNN with limited training data for ear recognition in the wild

- Tác giả: Ziga Emersic, Dejan Stepec, Peter Peer
- Tạp chí/ hội nghị: 2017 IEEE 12th International Conference on Automatic Face & Gesture Recognition

Trong bài báo này, vấn đề huấn luyện CNN với dữ liệu hạn chế được nêu ra và họ cố gắng phát triển một mô hình CNN hiệu quả hơn cho bài toán nhận dạng tai. Những cách tiếp cận hiện tại với dữ liệu nhỏ bao gồm:

- Tiếp cận học bằng độ đo, khi tập huấn luyện là các cặp ảnh hay vì các ảnh đơn.
- Tăng cường dữ liệu dựa trên hình học và độ nhiễu màu của tập huấn luyện hoặc là phương pháp tổng hợp mẫu dữ liệu.
- Sử dụng mạng CNN như là một bộ trích xuất đặc trưng.

5.5 Smart Augmentation Learning an Optimal Data Augmentation Strategy

- Tác giả: Joseph Lemley, Shabab Bazrafkan, Peter Corcoran
- Nguồn: arXiv:1703.08383v1 24 Mar 2017

Nhiều framework học sâu có khả năng tạo ra dữ liệu tăng cường. Ví dụ như Keras có một phương thức để ngẫu nhiên xoay, lật và phóng to hoặc thu nhỏ bức ảnh trong quá trình huấn luyện, nhưng không phải phương pháp nào cũng cải thiện hiệu năng và không

nên sử dụng một cách mù quáng. Những kỹ thuật tăng cường như xoay, lật và thêm nhiễu vào mẫu được miêu tả chi tiết và cách đo lường hiệu quả thu được khi sử dụng chúng cũng được mô tả. Họ còn đưa ra một danh sách đề xuất các phương pháp tăng cường dữ liệu. Vào năm 2014, Srivastava et al. giới thiệu kỹ thuật dropout, với mục tiêu là giảm overfitting, đặc biệt là trong trường hợp không đủ dữ liệu. Dropout hoạt động bằng cách tạm thời loại bỏ một neuron nhân tạo trong mạng và bỏ luôn bất kì liên kết nào đến neuron đó.

6. Phương pháp

6.1 Tổng quan CNN

Mạng neural tích chập (CNN) được phát triển từ nghiên cứu về vỏ não thi giác của con người và được sử dụng trong lĩnh vực nhận dạng ảnh điện tử từ năm 1980s. Trong 10 năm trở lại đây, nhờ vào sự cải tiến trong sức mạnh tính toán và dữ liệu lớn, CNNs đã đạt được hiệu năng siêu việt trên nhiều tác vụ thị giác phức tạp.

David H. Hubel và Torsten Wiesel thực hiện thí nghiệm trên loài mèo văn năm 1958 và 1959 rút ra nhiều hiểu biết quan trọng trong kiến trúc của vỏ não thi giác. Họ cho rằng nhiều neuron trong vỏ não thị giác có một trường thụ cảm cục bộ, nghĩa là chúng chỉ phản ứng với kích thích thị giác trong một vùng giới hạn của trường thị giác. Những trường thụ cảm này chứa nhiều neuron có thể chồng lấp lên nhau và cùng với nhau chúng tạo thành trường thị giác.

Kiến trúc CNN thông dụng gồm: Convolution + ReLU -> Pool -> Fully Connected -> Softmax loss

a. Lớp convolution

- Lớp dense học các khuôn mẫu toàn cục
- Lớp convolution học các khuôn mẫu cục bộ thông qua các filter
- Một neuron trong lớp convolution thứ 2 thì chỉ liên kết với những neuron ở một vùng chữ nhật nhỏ của lớp thứ nhất, cho phép tập trung vào những đặc trưng bậc thấp của lớp ẩn thứ nhất sau đó liên kết chúng lại thành đặc trưng bậc cao ở lớp ẩn tiếp theo.

- Có 3 loại convolution, trong xử lý ảnh thường dùng 2D Convolution, tức là filter có khả năng “trượt" hai chiều.
- Cơ chế hoạt động:
- Sử dụng một filters (hoặc kernels) tương tác với vùng thụ cảm thông qua phép nhân element-wise để cho ra một neuron trong lớp Convolution
- Filter trong lớp Convolution được định nghĩa qua ba tham số:
    - F: Kích thước filter, do filter luôn là ma trận vuông nên kích thước sẽ là F x F
    - S: Kích trước trượt, diễn tả filter sẽ trượt bao nhiêu đơn vị.
    - P: Vùng đệm, dùng để bổ sung các con số 0 dọc theo các trục tọa độ cho mục đích riêng.

b. Lớp pooling

- Công dụng: Làm giảm số lượng hệ số trong quá trình xử lý và làm giảm kích thước ảnh cho bước tiếp theo
- Thường dùng max pooling
- Max Pooling có thể xem là một filter với tác dụng trả về pixel lớn nhất trong một vùng trượt.
- Khác với vùng trượt trong lớp Convolution, vùng trượt trong Max Pooling không chồng lên nhau sau mỗi lần trượt, tức là một pixel chỉ đi qua filter một lần.

c. Fully connected

- Đưa ra mức độ diễn giải cao hơn cho mạng neural
- Rút trích đặc trưng toàn cục từ các đặc trưng cục bộ do lớp CNN tạo ra.

6.2 Phương pháp

a. Flow Diagram

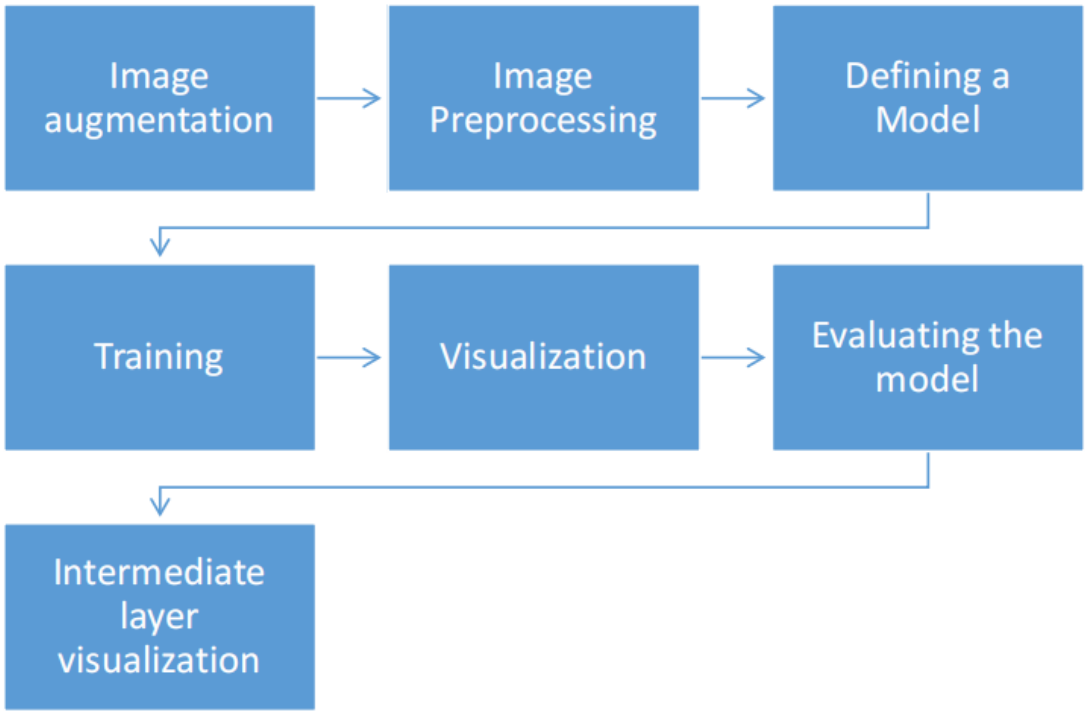
Image augmentation
Image Preprocessing
Defining a Model
Training
Visualization
Evaluating the model
Intermediate layer visualization

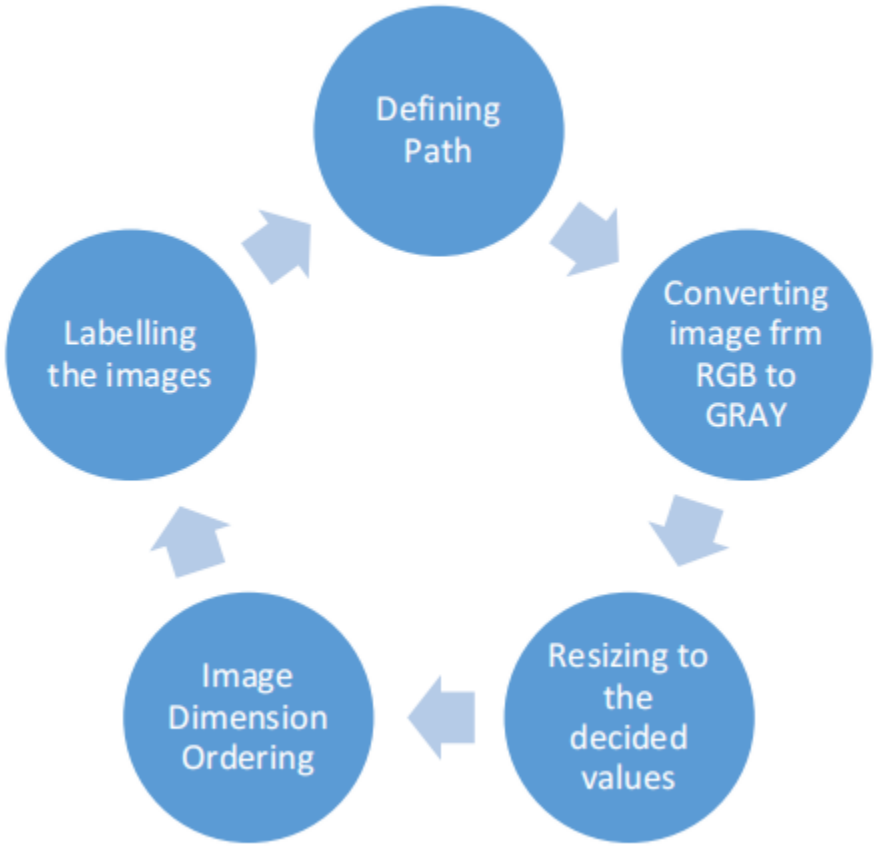
Defining Path
Converting image frm RGB to GRAY
Resizing to the decided values
Image Dimension Ordering
Labelling the images

- Data augmentation:

  Bộ dữ liệu có sẵn để huấn luyện không đủ để đạt độ chính xác cao. Do đó, cần tìm 1 cách để giải quyết vấn đề này. Một trong những cách đơn giản nhất là Image augmentation (tăng cường hình ảnh) bằng cách tạo thêm nhiều ảnh huấn luyện từ ảnh gốc bằng cách điều chỉnh các thông số như góc quay, độ sáng, lật ngang- dọc … Ý tưởng này mô phỏng những thay đổi của ảnh trong thực tế khi bị tác động bởi các yếu tố ngoại cảnh như độ sáng, góc chụp, biến dạng ảnh …

FILTER	VALUE	DESCRIPTION
Rotation range	0-30 degrees	Nếu góc chạm quá 30 độ, các đặc trưng có thể không được trích xuất
Width shift range	0.2	Nếu vượt quá, hình ảnh có thể không được tăng cường chính xác.
Height shift range	0.2	Nếu vượt quá, hình ảnh có thể không được tăng cường chính xác.
Shear range	0.2	Giá trị này là hoàn hảo cho mô hình
Zoom range	0.2	Phạm vi thu phóng này sẽ tạo ra ảnh mờ
ZCA whitening	True	Tạo ra ảnh trắng để dễ hình dung

Rescale	1.2	Giá trị này là hoàn hảo cho mô hình

- Data preprocessing (tiền xử lý dữ liệu):

Vì số lượng ảnh huấn luyện rất lớn nên bước tiền xử lý rất quan trọng để rút ngắn thời gian cũng như tăng hiệu suất huấn luyện. Tiền xử lý gồm:

- Đặt kích thước chuẩn cho hình ảnh là 128x128 để giảm thời gian tải ảnh.
- Chuyển ảnh từ 3 kênh màu RGB sang 1 kênh thang độ xám.
- Gán nhãn theo từng lớp để thực hiện học có giám sát.
- Chia tập huấn luyện thành 2 tập huấn luyện và đánh giá với tỉ lệ 8:2.
- Định nghĩa mô hình:

Mô hình được xây dựng dựa trên kiến trúc CNN. Mô hình gồm 3 lớp conv, 3 lớp activation, 2 lớp max_pooling và 2 lớp dropout.

Tóm tắt mô hình được mô tả ở bảng.

Layer (type)	Output Shape	Param #
conv2d_1 (Conv2D)	(None, 128, 128, 32)	320
activation_1 (Activation)	(None, 128, 128, 32)	0
conv2d_2 (Conv2D)	(None, 126, 126, 32)	9248
activation_2 (Activation)	(None, 126, 126, 32)	0
max_pooling2d_1 (MaxPooling2	(None, 63, 63, 32)	0
dropout_1 (Dropout)	(None, 63, 63, 32)	0
conv2d_3 (Conv2D)	(None, 61, 61, 64)	18496
activation_3 (Activation)	(None, 61, 61, 64)	0
max_pooling2d_2 (MaxPooling2	(None, 30, 30, 64)	0
dropout_2 (Dropout)	(None, 30, 30, 64)	0
flatten_1 (Flatten)	(None, 57600)	0
dense_1 (Dense)	(None, 64)	3686464
activation_4 (Activation)	(None, 64)	0
dropout_3 (Dropout)	(None, 64)	0
dense_2 (Dense)	(None, 11)	715
activation_5 (Activation)	(None, 11)	0

- Training:

Việc đào tạo mô hình có thể được thực hiện bằng cách chạy 1 số lượng epochs. Đây là chức năng chạy các epochs cho đến khi quan sát thấy rằng sự mất mát được cải thiện và các giá trị của trọng số, có sai số nhỏ nhất, được lưu lại. Biến hist lưu trữ kết quả độ chính xác và tổn thất có thể được sử dụng để vẽ biểu đồ bằng cách đưa ra làm đầu vào cho mô hình tiếp theo. Batch size được đặt thành 16 và số epochs là 200.

Quá trình đào tạo diễn ra trên 900 hình ảnh và 200 hình ảnh để xác thực. 1 epochs mất khoảng 5-6 giây trên GPU, trong khi 160 hình ảnh mất 20 giây để chạy một epochs. Điều này cho thấy GPU hiệu quả hơn so với CPU.

- Visualization:

Trong quá trình huấn luyện này, biến hist đã lưu trữ tổn thất và độ chính xác sẽ được sử dụng để vẽ biểu đồ. 2 số liệu trên sẽ được vẽ với trục Y là tổn thất hoặc độ chính xác và trên trục X là số epochs. Biểu đồ này được sử dụng để biết mạng đang đào tạo tốt như thế nào và chúng ta cũng có thể biết có bao nhiêu epoch có lợi cho hệ thống.

- Evaluting the model:

Bước này, hệ thống sẽ lấy một hình ảnh ngẫu nhiên từ bộ validation và dự đoán hình ảnh đó rồi in đầu ra. Ngoài ra, đầu ra ở dạng giá trị xác suất từ tất cả các lớp. Lớp có giá trị cao nhất là dự đoán của hệ thống.

- Intermediate layer visulization:

Bước này rất quan trọng cho thấy liệu mô hình có được đào tạo chính xác hay không. Hình ảnh cần thiết được dùng để huấn luyện sẽ được trực quan qua các bước để xem những gì được thực hiện trên các lớp. Sau đó, Confusion matrix được sử dụng để biết độ chính xác của từng lớp. Đây là 1 ma trận với 1 trục biểu thị các nhãn thực và 1 trục biểu thị các nhãn dự đoán.

b. Tính năng của hệ thống:

Các module chính trong hệ thống là:

- Mô-đun tăng cường
- Mô-đun tiền xử lý
- Mô đun định nghĩa mô hình
- Mô đun đào tạo
- Mô-đun trực quan hóa
- Mô đun đánh giá

c. Flow chart


Image augmentation
•Rotation:45 degrees
• zca_whitening= True,
• horizontal_flip=False,
• rescale=1.2
Image preprocessing
•RGB to GRAY
•Resizing
•Dimension ordering
•Labelling spliting
Defining a model
•ConV layers
•Activations
•Dropouts
•SGD Optimizer
Training
•Batch size = 16
•Verbose = 1
•epochs = ~200
•Callbacks
Visualizations
• Training and validation accuracy vs no. of epochs
• Training and validation loss vs no. of epochs
Evaluation
• Predicting from val_image
• Testing entire new image
Visualizations
• Visualizing intermediate layers
• Generating Confusion Matrix
• Plotting the Matrix
Saving the model
• Loading the model
• Saving the model

7. Demo

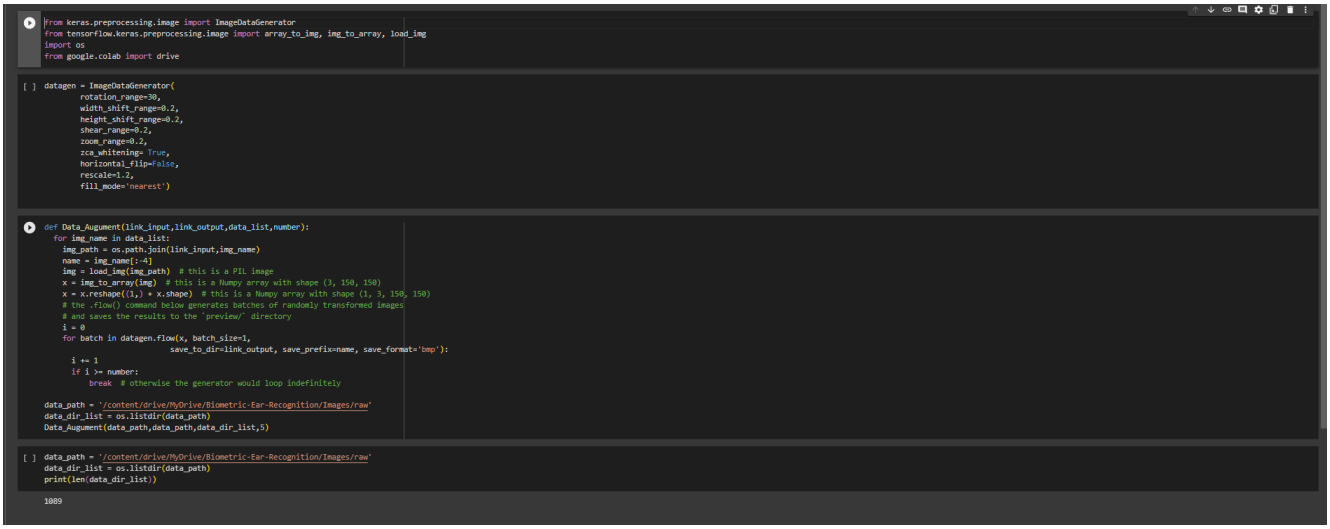

```
from keras.preprocessing.image import ImageDataGenerator
from tensorflow.keras.preprocessing.image import array_to_img, img_to_array, load_img
import os
from google.colab import drive
```

```
datagen = ImageDataGenerator(
        rotation_range=30,
        width_shift_range=0.2,
        height_shift_range=0.2,
        shear_range=0.2,
        zoom_range=0.2,
        zca_whitening= True,
        horizontal_flip=False,
        rescale=1.2,
        fill_mode='nearest')
```

```
def Data_Augument(link_input,link_output,data_list,number):
  for img_name in data_list:
    img_path = os.path.join(link_input,img_name)
    name = img_name[:-4]
    img = load_img(img_path)  # this is a PIL image
    x = img_to_array(img)  # this is a Numpy array with shape (3, 150, 150)
    x = x.reshape((1,) + x.shape)  # this is a Numpy array with shape (1, 3, 150, 150)
    # the .flow() command below generates batches of randomly transformed images
    # and saves the results to the `preview/` directory
    i = 0
    for batch in datagen.flow(x, batch_size=1,
                              save_to_dir=link_output, save_prefix=name, save_format='bmp'):
      i += 1
      if i >= number:
          break  # otherwise the generator would loop indefinitely

data_path = '/content/drive/MyDrive/Biometric-Ear-Recognition/Images/raw'
data_dir_list = os.listdir(data_path)
Data_Augument(data_path,data_path,data_dir_list,5)
```

```
data_path = '/content/drive/MyDrive/Biometric-Ear-Recognition/Images/raw'
data_dir_list = os.listdir(data_path)
print(len(data_dir_list))
```

```
1089
```

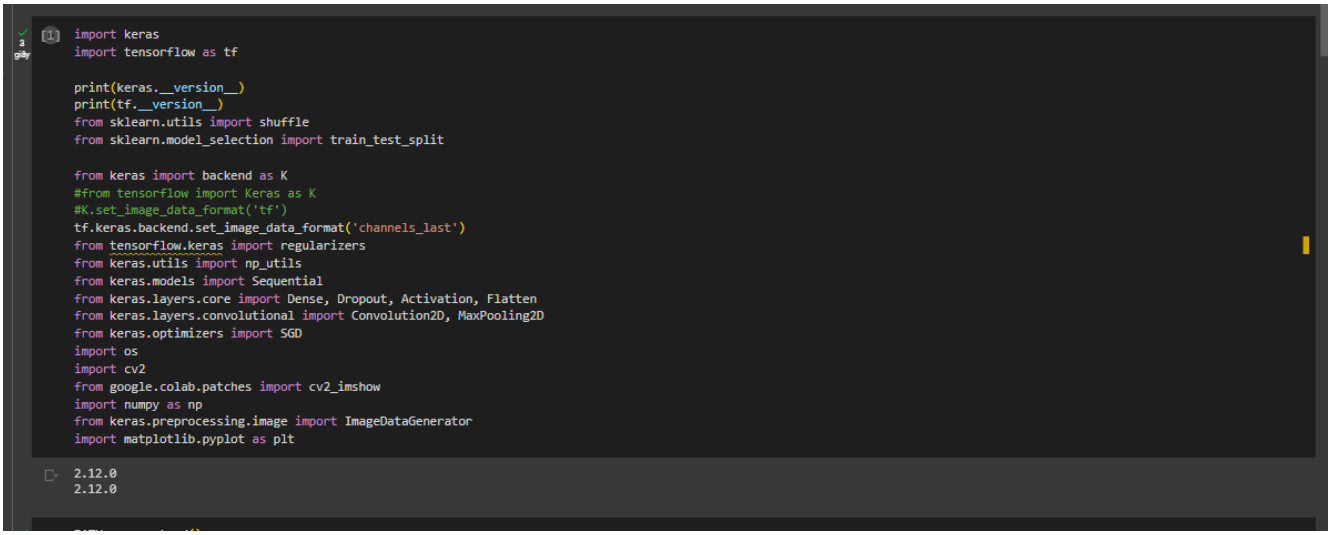

```
import keras
import tensorflow as tf

print(keras.__version__)
print(tf.__version__)
from sklearn.utils import shuffle
from sklearn.model_selection import train_test_split

from keras import backend as K
#from tensorflow import Keras as K
#K.set_image_data_format('tf')
tf.keras.backend.set_image_data_format('channels_last')
from tensorflow.keras import regularizers
from keras.utils import np_utils
from keras.models import Sequential
from keras.layers.core import Dense, Dropout, Activation, Flatten
from keras.layers.convolutional import Convolution2D, MaxPooling2D
from keras.optimizers import SGD
import os
import cv2
from google.colab.patches import cv2_imshow
import numpy as np
from keras.preprocessing.image import ImageDataGenerator
import matplotlib.pyplot as plt
```

```
2.12.0
2.12.0
```

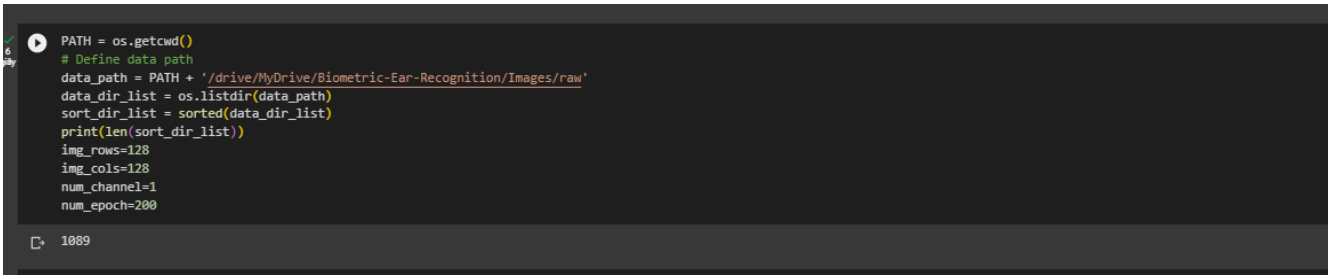

```
PATH = os.getcwd()
# Define data path
data_path = PATH + '/drive/MyDrive/Biometric-Ear-Recognition/Images/raw'
data_dir_list = os.listdir(data_path)
sort_dir_list = sorted(data_dir_list)
print(len(sort_dir_list))
img_rows=128
img_cols=128
num_channel=1
num_epoch=200
```

```
1089
```

```
[3] img_data_list=[]

    for bmp in sort_dir_list:
        img_path = os.path.join(data_path,bmp)
        input_img= cv2.imread(img_path)
        input_img=cv2.cvtColor(input_img, cv2.COLOR_BGR2GRAY)
        input_img_resize=cv2.resize(input_img,(128,128))
        img_data_list.append(input_img_resize)

    img_data = np.array(img_data_list)
    img_data = img_data.astype('float32')
    img_data /= 255
    print (img_data.shape)
```

```
(1089, 128, 128)
```

```
if num_channel==1:
  if tf.keras.backend.image_data_format()=='th':
    img_data= np.expand_dims(img_data, axis=1)
    print (img_data.shape)
  else:
    img_data= np.expand_dims(img_data, axis=3)
    print (img_data.shape)

else:
  if K.backend.image_data_format()=='th':
    img_data=np.rollaxis(img_data,3,1)
    print (img_data.shape)
```

```
(1089, 128, 128, 1)
```

```
#%%
# Assigning Labels

# Define the number of classes
num_classes = 51

num_of_samples = img_data.shape[0]

labels = np.ones((num_of_samples,),dtype='int64')

count = 0
precount = count
count_class = 1
for img in  sort_dir_list:
  if int(img[1:3]) == count_class:
    count+=1
  else:
    labels[precount:count] = count_class
    precount = count
    count_class += 1
    count+=1
labels[precount:6681] = count_class
# convert class labels to on-hot encoding
Y = np_utils.to_categorical(labels, num_classes)
print(Y)
```

```
[[0. 1. 0. ... 0. 0. 0.]
 [0. 1. 0. ... 0. 0. 0.]
 [0. 1. 0. ... 0. 0. 0.]
 ...
 [0. 0. 0. ... 0. 0. 1.]
 [0. 0. 0. ... 0. 0. 1.]
 [0. 0. 0. ... 0. 0. 1.]]
```

```
[6] #Shuffle the dataset
    x,y = shuffle(img_data,Y, random_state=2)
    # Split the dataset
    X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=2)
    print(y_test)
```

```
[[0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 ...
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 1. 0. 0.]]
```

```
#%%
# Defining the model
# img_data = tf.expand_dims(img_data,axis=-1)
print(img_data.shape)
input_shape=img_data[0].shape
print(input_shape)

model = Sequential()
model.add(Convolution2D(32, 3, padding='same', activation='relu', input_shape= input_shape))
model.add(MaxPooling2D((2, 2)))
model.add(Dropout(0.25))

model.add(Convolution2D(64, (3, 3), padding='same', activation='relu'))
model.add(MaxPooling2D((2, 2)))
model.add(Dropout(0.5))

model.add(Convolution2D(128, (3, 3), padding='same', activation='relu'))
model.add(Convolution2D(128, (3, 3), padding='same', activation='relu'))
model.add(MaxPooling2D((2, 2)))
model.add(Dropout(0.5))

model.add(Flatten())
model.add(Dense(512, activation='relu', kernel_regularizer=regularizers.l2(0.01)))
model.add(Dropout(0.5))

model.add(Dense(256, activation='relu', kernel_regularizer=regularizers.l2(0.01)))
model.add(Dropout(0.5))

model.add(Dense(num_classes, activation='softmax'))

#sgd = SGD(lr=0.01, decay=5e-4, momentum=0.9, nesterov=True)
model.compile(loss='categorical_crossentropy', optimizer= 'adam',metrics=["accuracy"])
#model.compile(loss='categorical_crossentropy', optimizer='rmsprop',metrics=["accuracy"])

# Viewing model_configuration

model.summary()
model.get_config()
model.layers[0].get_config()
model.layers[0].input_shape
model.layers[0].output_shape
model.layers[0].get_weights()
np.shape(model.layers[0].get_weights()[0])
model.layers[0].trainable
```

```
(1089, 128, 128, 1)
(128, 128, 1)
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv2d (Conv2D)             (None, 128, 128, 32)      320

 max_pooling2d (MaxPooling2D  (None, 64, 64, 32)       0
 )

 dropout (Dropout)           (None, 64, 64, 32)        0

 conv2d_1 (Conv2D)           (None, 64, 64, 64)        18496

 max_pooling2d_1 (MaxPooling  (None, 32, 32, 64)       0
 2D)

 dropout_1 (Dropout)         (None, 32, 32, 64)        0

 conv2d_2 (Conv2D)           (None, 32, 32, 128)       73856

 conv2d_3 (Conv2D)           (None, 32, 32, 128)       147584

 max_pooling2d_2 (MaxPooling  (None, 16, 16, 128)      0
 2D)

 dropout_2 (Dropout)         (None, 16, 16, 128)       0

 flatten (Flatten)           (None, 32768)             0

 dense (Dense)               (None, 512)               16777728

 dropout_3 (Dropout)         (None, 512)               0

 dense_1 (Dense)             (None, 256)               131328

 dropout_4 (Dropout)         (None, 256)               0

 dense_2 (Dense)             (None, 51)                13107

=================================================================
Total params: 17,162,419
Trainable params: 17,162,419
Non-trainable params: 0
_________________________________________________________________
True
```

```
Epoch 1993/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.9687 - accuracy: 0.8932 - val_loss: 3.4680 - val_accuracy: 0.7752
Epoch 1994/2000
55/55 [==============================] - 0s 7ms/step - loss: 3.0128 - accuracy: 0.8990 - val_loss: 3.4465 - val_accuracy: 0.7661
Epoch 1995/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.9527 - accuracy: 0.9082 - val_loss: 3.3749 - val_accuracy: 0.7936
Epoch 1996/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.9146 - accuracy: 0.9059 - val_loss: 3.2413 - val_accuracy: 0.7982
Epoch 1997/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.8969 - accuracy: 0.9013 - val_loss: 3.3192 - val_accuracy: 0.8073
Epoch 1998/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.9130 - accuracy: 0.8967 - val_loss: 3.3495 - val_accuracy: 0.7982
Epoch 1999/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.9072 - accuracy: 0.8921 - val_loss: 3.3865 - val_accuracy: 0.7890
Epoch 2000/2000
55/55 [==============================] - 0s 7ms/step - loss: 2.9328 - accuracy: 0.9024 - val_loss: 3.3101 - val_accuracy: 0.8073
2000
```

```
[8] # Training
    num_epoch = 2000
    hist = model.fit(X_train, y_train, batch_size=16, epochs=num_epoch, verbose=1, validation_data=(X_test, y_test))
    #hist = model.fit(X_train, y_train, batch_size=32, nb_epoch=20,verbose=1, validation_split=0.2)
    print(num_epoch)
```

```
# Training with callbacks
from keras import callbacks

filename='model_train_new.csv'
csv_log=callbacks.CSVLogger(filename, separator=',', append=False)

early_stopping=callbacks.EarlyStopping(monitor='val_loss', min_delta=0, patience=0, verbose=0, mode='min')

filepath="Best-weights-my_model-{epoch:03d}-{loss:.4f}-{accuracy:.4f}.hdf5"

checkpoint = callbacks.ModelCheckpoint(filepath, monitor='val_loss', verbose=1, save_best_only=True, mode='min')

callbacks_list = [csv_log,early_stopping,checkpoint]

hist = model.fit(X_train, y_train, batch_size=16, epochs=num_epoch, verbose=1, validation_data=(X_test, y_test),callbacks=callbacks_list)
```

```
Epoch 1/2000
55/55 [==============================] - ETA: 0s - loss: 2.9427 - accuracy: 0.8886
Epoch 1: val_loss improved from inf to 3.40118, saving model to Best-weights-my_model-001-2.9427-0.8886.hdf5
55/55 [==============================] - 1s 14ms/step - loss: 2.9427 - accuracy: 0.8886 - val_loss: 3.4012 - val_accuracy: 0.7890
Epoch 2/2000
51/55 [==========================>...] - ETA: 0s - loss: 2.9598 - accuracy: 0.8897
Epoch 2: val_loss improved from 3.40118 to 3.35825, saving model to Best-weights-my_model-002-2.9543-0.8932.hdf5
55/55 [==============================] - 1s 12ms/step - loss: 2.9543 - accuracy: 0.8932 - val_loss: 3.3583 - val_accuracy: 0.8119
Epoch 3/2000
51/55 [==========================>...] - ETA: 0s - loss: 2.8784 - accuracy: 0.9240
Epoch 3: val_loss improved from 3.35825 to 3.28684, saving model to Best-weights-my_model-003-2.8746-0.9242.hdf5
55/55 [==============================] - 1s 12ms/step - loss: 2.8746 - accuracy: 0.9242 - val_loss: 3.2868 - val_accuracy: 0.8028
Epoch 4/2000
51/55 [==========================>...] - ETA: 0s - loss: 2.9171 - accuracy: 0.9020
Epoch 4: val_loss did not improve from 3.28684
55/55 [==============================] - 0s 7ms/step - loss: 2.9221 - accuracy: 0.8978 - val_loss: 3.3256 - val_accuracy: 0.7982
```

```
#%%
# visualizing losses and accuracy
train_loss=hist.history['loss']
val_loss=hist.history['val_loss']
train_acc=hist.history['accuracy']
val_acc=hist.history['val_accuracy']
xc=range(len(train_loss))
plt.figure(1,figsize=(7,5))
plt.plot(xc,train_loss)
plt.plot(xc,val_loss)
plt.xlabel('num of Epochs')
plt.ylabel('loss')
plt.title('train_loss vs val_loss')
plt.grid(True)
plt.legend(['train','val'])
#print plt.style.available # use bmh, classic,ggplot for big pictures
plt.style.use(['classic'])

plt.figure(2,figsize=(7,5))
plt.plot(xc,train_acc)
plt.plot(xc,val_acc)
plt.xlabel('num of Epochs')
plt.ylabel('accuracy')
plt.title('train_acc vs val_acc')
plt.grid(True)
plt.legend(['train','val'],loc=4)
#print plt.style.available # use bmh, classic,ggplot for big pictures
plt.style.use(['classic'])

#%%
```

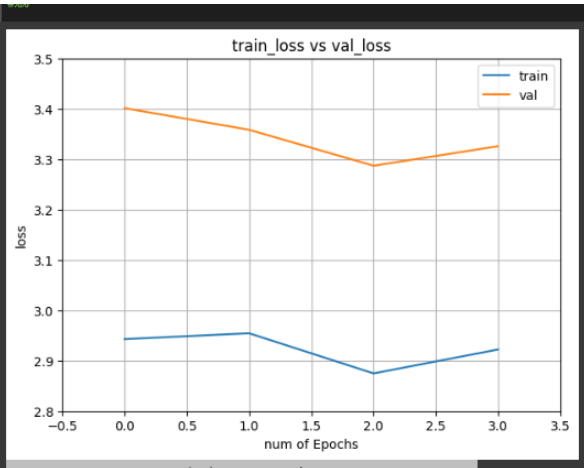

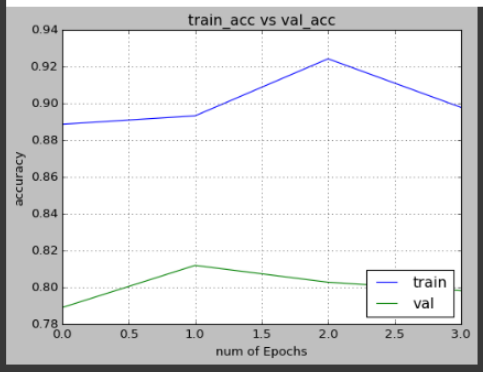


```
# Evaluating the model

score = model.evaluate(X_test, y_test, verbose=0)
print('Test Loss:', score[0])
print('Test accuracy:', score[1])

test_image = X_test[0:100]
print (test_image.shape)
y_pred = model.predict(test_image)
predicted_classes = np.argmax(y_pred[0])
print(predicted_classes)
print(np.argmax(y_test[0:100]))
```

```
Test Loss: 3.3256077766418457
Test accuracy: 0.7981651425361633
(100, 128, 128, 1)
4/4 [==============================] - 0s 28ms/step
34
34
```

```python
# Testing a new image
# test_image = cv2.imread('raw/002_3_0_1923.bmp')

def predict_new_image(test_link,name):
  link_image = os.path.join(test_link,name)
  test_image = cv2.imread(link_image)
  test_image=cv2.cvtColor(test_image, cv2.COLOR_BGR2GRAY)
  test_image=cv2.resize(test_image,(128,128))
  test_image = np.array(test_image)
  test_image = test_image.astype('float32')
  test_image /= 255

  if num_channel==1:
    if K.image_data_format()=='th':
      test_image= np.expand_dims(test_image, axis=0)
      test_image= np.expand_dims(test_image, axis=0)
      #print (test_image.shape)
    else:
      #test_image= np.expand_dims(test_image, axis=3)
      test_image= np.expand_dims(test_image, axis=2)
      test_image= np.expand_dims(test_image, axis=0)
      #print (test_image.shape)

  else:
    if K.image_data_format()=='th':
      test_image=np.rollaxis(test_image,2,0)
      test_image= np.expand_dims(test_image, axis=0)
      #print (test_image.shape)
    else:
      test_image= np.expand_dims(test_image, axis=0)
      #print (test_image.shape)

  # Predicting the test image
  y_pre = model.predict(test_image)
  temp = y_pre[0]
  predict_classes = np.argmax(temp)
  return (int(name[1:3]),predict_classes)
test_link = '/content/drive/MyDrive/Biometric-Ear-Recognition/Images/test'
test_dir_list = os.listdir(test_link)
acc_test = 0
for img in test_dir_list:
  y,pre_y = predict_new_image(test_link,img)
  print(y,pre_y)
  if y == pre_y:
    acc_test+=1
print(acc_test/186)
```

```
45 49
37 37
1/1 [==============================] - 0s 19ms/step
48 48
1/1 [==============================] - 0s 19ms/step
31 31
1/1 [==============================] - 0s 19ms/step
43 22
1/1 [==============================] - 0s 20ms/step
42 42
1/1 [==============================] - 0s 19ms/step
46 46
1/1 [==============================] - 0s 21ms/step
49 49
1/1 [==============================] - 0s 20ms/step
49 42
1/1 [==============================] - 0s 20ms/step
50 50
1/1 [==============================] - 0s 20ms/step
50 26
0.8118279569892473
```

```python
# Printing the confusion matrix
from sklearn.metrics import classification_report,confusion_matrix
import itertools

Y_pred = model.predict(X_test)
print(Y_pred)
y_pred = np.argmax(Y_pred, axis=1)
print(y_pred)
#y_pred = model.predict_classes(X_test)
#print(y_pred)
target_names = ['true label']

#print(classification_report(np.argmax(y_test,axis=1), y_pred,target_names=target_names))

print(confusion_matrix(np.argmax(y_test,axis=1), y_pred))
```

```
7/7 [==============================] - 0s 3ms/step
[[1.21e-18 1.09e-10 2.94e-13 ... 1.54e-08 3.05e-19 5.39e-15]
 [5.69e-12 3.71e-06 4.12e-09 ... 1.65e-09 9.66e-11 2.02e-10]
 [2.60e-11 9.28e-08 1.22e-06 ... 2.79e-06 6.54e-08 2.19e-11]
 ...
 [2.72e-14 5.03e-07 2.84e-14 ... 1.06e-05 4.32e-01 1.43e-02]
 [3.55e-23 1.07e-08 1.67e-08 ... 1.66e-13 1.21e-20 1.83e-12]
 [1.02e-25 1.64e-17 9.08e-14 ... 1.00e+00 8.24e-15 3.00e-11]]
[34 35 13 17 29 44  7 27 15 27 15 33 12 20 13 17 14 25 34 31 47 36  1 14
 14 41 39 22 47  6 18 29  2 18 35 24 44 37 32 37 42  2 29  4 10 31 23 42
  5 30 28  8 13 21  6 20 31  2 12 32 39 30 30 50 10 16 46  2 29  6 47 41
 44  4 39 28 26 39 49 13 31 12 13  9 44 21 40 19 21 33 31 17  8 16  7 33
 22 13 13 20 23 42  4 34  2  1  1  1 28 34 26 49 13 40  2  7  4 20 15 34
 10 47 13 31 41  1  2 22 35 10 24 33 48 12 23  5 21 48 10 14 30  6 50 13
 17 30 13 38  7 44 13  9 13 47 37 36 48 22 30 28  2 20 41 19 32 48 36 20
  2 32  6 39  5 23 14 23 44 27 39 16 50 28 20  3  1 48 46 30 37 33  3  6
 40 23 33 36 48 10 27 13 19  8 25  8 12 37  4 42 34 28 39  1 12 26 42  7
 32 48]
[[6 0 0 ... 0 0 0]
 [0 8 0 ... 0 0 0]
 [0 0 2 ... 0 0 0]
 ...
 [0 0 0 ... 7 0 0]
 [0 0 0 ... 0 2 0]
 [0 0 0 ... 0 0 3]]
```

```python
# Plotting the confusion matrix
def plot_confusion_matrix(cm, classes,
                          normalize=False,
                          title='Confusion matrix',
                          cmap=plt.cm.Blues):
    """
    This function prints and plots the confusion matrix.
    Normalization can be applied by setting `normalize=True`.
    """
    plt.imshow(cm, interpolation='nearest', cmap=cmap)
    plt.title(title)
    plt.colorbar()
    tick_marks = np.arange(len(classes))
    plt.xticks(tick_marks, classes, rotation=45)
    plt.yticks(tick_marks, classes)

    if normalize:
        cm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]
        print("Normalized confusion matrix")
    else:
        print('Confusion matrix, without normalization')

    print(cm)

    thresh = cm.max() / 2.
    for i, j in itertools.product(range(cm.shape[0]), range(cm.shape[1])):
        plt.text(j, i, cm[i, j],
                 horizontalalignment="center",
                 color="white" if cm[i, j] > thresh else "black")

    plt.tight_layout()
    plt.ylabel('True label')
    plt.xlabel('Predicted label')
# Compute confusion matrix
cnf_matrix = (confusion_matrix(np.argmax(y_test,axis=1), y_pred))

np.set_printoptions(precision=2)

plt.figure()

# Plot non-normalized confusion matrix
plot_confusion_matrix(cnf_matrix, classes=target_names,
                      title='Confusion matrix')
#plt.figure()
# Plot normalized confusion matrix
#plot_confusion_matrix(cnf_matrix, classes=target_names, normalize=True,
#                      title='Normalized confusion matrix')
#plt.figure()
plt.show()
```

8. Tài liệu tham khảo

1. M. Burge, W. Burger, Biometrics: Personal Identification in Networked Society, Springer US, Boston, MA, 1996, Ch. Ear Biometrics, pp. 273–285.

2.K. Chang, K. W. Bowyer, S. Sarkar, B. Victor, Comparison and combination of ear and face images in appearance-based biometrics, Transactions on Pattern Analysis and Machine Intelligence 25 (9) (2003) 1160–1165.

3.H.-J. Zhang, Z.-C. Mu, W. Qu, L.-M. Liu, C.-Y. Zhang, A novel approach for ear recognition based on ICA and RBF network, in: Proceedings of the International Conference on Machine Learning and Cybernetics, Vol. 7, IEEE, 2005, pp. 4511–4515.

4.K. Dewi, T. Yahagi, Ear photo recognition using scale invariant keypoints., in: Proceedings of the Computational Intelligence, 2006, pp. 253–258.

5.M. Alaraj, J. Hou, T. Fukami, A neural network based human identification framework using ear images, in: Proceedings of the International technical conference of IEEE Region 10, IEEE, 2010, pp. 1595–1600.

6.P. Galdamez, A. Gonzalez Arrieta, M. Ramon, Ear recognition using a hybrid approach based on neural networks, in: Proceedings of the International Conference on Information Fusion, 2014, pp. 1–6.

7.A. Morales, M. Diaz, G. Llinas-Sanchez, M. Ferrer, Earprint recognition based on an ensemble of global and local features, in: Proceedings of the International Carnahan Conference on Security Technology, IEEE, 2015, pp. 253–258.

8.A. Benzaoui, A. Kheider, A. Boukrouche, Ear description and recognition using ELBP and wavelets, in: Proceedings of the International Conference on Applied Research in Computer Science and Engineering, 2015, pp. 1–6.

9.A. Meraoumia, S. Chitroub, A. Bouridane, An automated ear identification system using Gabor filter responses, in: Proceedings of the International Conference on New Circuits and Systems, IEEE, 2015, pp. 1–4

10.Alshazly Hammam, Linse Christoph, Barth Erhardt, Idris Sahar Ahmed, and Martinetz Thomas. 2021. Towards explainable ear recognition systems using deep residual networks. *IEEE Access* 9 (2021), 122254–122273

11.Aiadi Oussama, Khaldi Belal, and Saadeddine Cheraa. 2022. MDFNet: An unsupervised lightweight network for ear print recognition. *Journal of Ambient Intelligence and Humanized Computing* (2022)

12. Ear Biometrics Using Deep Learning: A Survey. https://www.hindawi.com/journals/acisc/2022/9692690/

13.Ear Recognition: More Than a Survey.
https://arxiv.org/pdf/1611.06203.pdf

14. https://arxiv.org/pdf/1710.07662v1.pdf